

畳み込みとGCN

今回の解説 の流れ

畳み込みって何？

- そもそも何をしたい概念？
- 教科書に出てくる数式と、GCNで使う数式が違うように見えるのはなぜ？
- 1次元の例で考える畳み込み（Spatialな場合）
- 1次元の例で考える畳み込み（Spectralな場合）

Spatial GCN

- Spatial GCNの概要
- Spatial GCNの計算コスト

Spectral GCN

- Spectral GCNの概要
- Spectral GCNの計算コスト

畳み込みって何？

そもそも何をしたい概念？

$$y(t) = g(t) * x(t)$$


もとの関数にフィルターをかける！

- 何のために？


→用途は様々！（だから概要をつかみにくい…）

今回は特徴をはっきりさせるため

畳み込み前





畳み込み後



特徴をはっきりさせる？

- これを2次元画像に対して使う
→CNN
- これをグラフ（ネットワーク）
に対して使う
→GCN

畳み込みで関数の
特徴を際立たせている！



教科書の数式とは違うように見えるのは？

私たちは…

$$x_{k+1,j} = L_k h \left(\sum_{i=1}^{f_{k-1}} \boxed{F_{k,i,j}} x_{k,i} \right) \quad (j = 1 \dots f_k)$$

ここが「重み」 (のようなもの)

な式を読めるようになって、活用したい！

しかし、畳み込みについて、書籍を開いても、web上の情報を検索しても

$$(f * g)(t) = \int f(\tau) g(t - \tau) d\tau \quad \text{や} \quad (f * g)(m) = \sum_n f(n) g(m - n)$$

という式しか出てこない…なぜ？

「因果的な時不変システム」を取り扱う際に便利な形式だから！

「過去の出来事が、現在にどれだけ影響しているのか」といったことをモデル化する際に便利！（ここでは詳しくは説明しない。）

$t - \tau$ という部分が気になるところだが、より重要なことは『元の関数に「重み」をかけて、強調したり、捨象したりしている』という構造！

一般的（より広い意味）に考えると…

→元の関数に「重み」をかけて、強調するところと、捨象するところの区別をする　ということがキモ！

畳み込みの一般的な形

連続的な場合

$$y(t) = (f * g)(t) = \int f(\tau) g(t, \tau) d\tau$$

離散的な場合

$$y(m) = (f * g)(m) = \sum_n f(n) g(m, n)$$

重み

具体例 (nは0から4まで変化させる)

n	0	1	2	3	4
f	0	2	4	6	8

m - n	-1	0	1
g	5	3	1

m	0	1	2	3	4
y		$0 \times 1 + 1 \times 3 + 4 \times 5 = 23$	$2 \times 1 + 4 \times 3 + 6 \times 5 = 44$	$4 \times 1 + 6 \times 3 + 8 \times 5 = 62$	

$$f(n) = \{0, 2, 4, 6, 8\}$$



$$g(m, n) = \begin{cases} 1, & m - n = 1 \text{ のとき} \\ 3, & m - n = 0 \text{ のとき} \\ 5, & m - n = -1 \text{ のとき} \\ 0, & \text{上記以外} \end{cases}$$

$$y(m) = \{-, 23, 44, 62, -\}$$


空間的の意

Spatialな場合

ノイズが目立たなくなり、形がはっきりする！





Spatialな場合（どんな手順で？）



スペクトルの意

Spectralな場合


スペクトルに分解することで、特徴的な成分が明らかに！



Spectralな場合（どんな手順で？）

これが「スペクトル」！

どの周波数の成分の強度
が大きいのか知ることが
できる




$$f(t) = 100 \sin(2\pi \cdot 10t) + 5 \sin(2\pi \cdot 42t) + 20 \sin(2\pi \cdot 46t) + 30 \sin(2\pi \cdot 48t)$$

(離散) フーリエ変換

$$F(t) = \sum_{x=0}^{N-1} f(x) \exp\left(-i \frac{2\pi t x}{N}\right)$$

重み

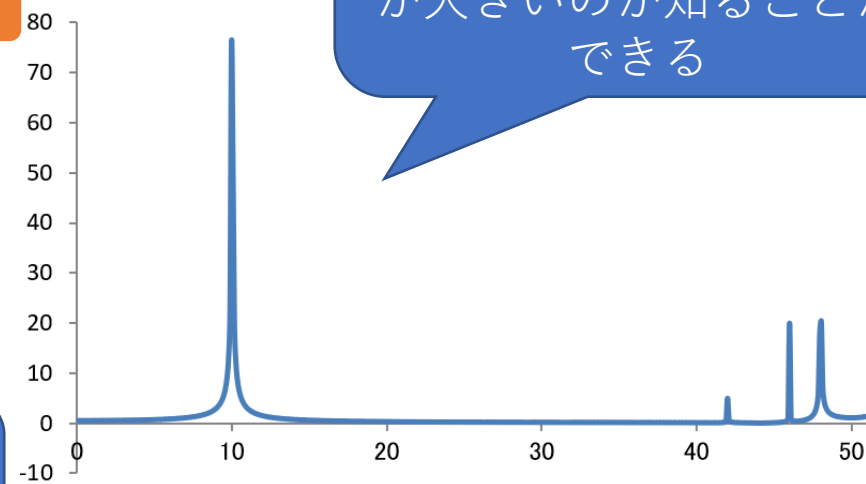
複雑な関数も（様々な周波数の）
三角関数などの足し合わせとして
表現できる！



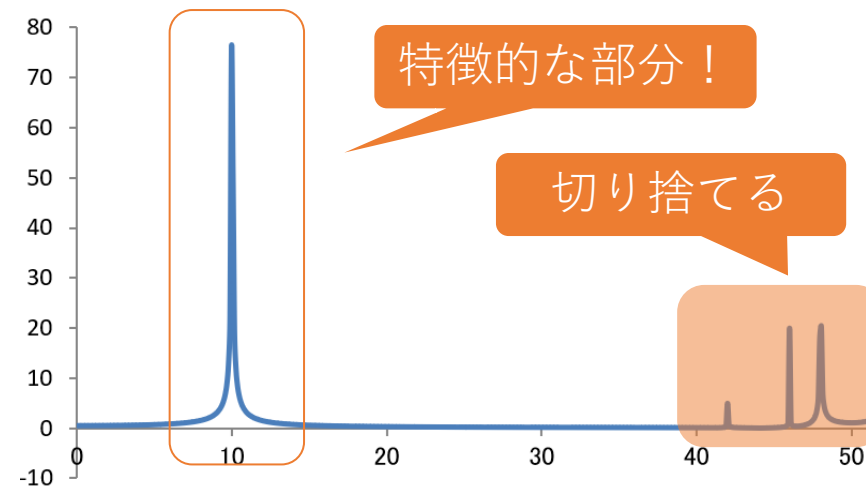
$$f(t) = 100 \sin(2\pi \cdot 10t)$$

逆（離散）フーリエ変換

$$f(x) = \frac{1}{N} \sum_{t=0}^{N-1} F(t) \exp\left(i \frac{2\pi x t}{N}\right)$$



注目部分を取り出す



特徴的な部分！

切り捨てる

ここまでの まとめ

- 畳み込み→フィルターをかけること
- Spatialな場合→ノイズを目立たなくさせ、特徴をはっきり
- Spectralな場合→スペクトルに分解することで、特徴をはっきり
- これを2次元画像に用いる→CNN
- これを「グラフ」に用いる→GCN
- 大雑把に知りたいだけならば、ここまででOK！

Spatial GCN



この章の流れ

- 理解の前提となる事柄を解説する。


「グラフ」について簡単に説明

- J.Brunaらが2014年に発表した
"Spectral Networks and Deep Locally Connected
Networks on Graphs"
の内容をもとにしてSpatial GCNを紹介する。

「グラフ畳み込み」を定式化した最初期の論文（無料で読める！）

- ざっくりと式の流れを追いかける。
- 計算コストについて簡単に考察する。

「グラフ」って何？



- 一言でいうと「ネットワーク」のこと
- ノード（頂点）とノードとがエッジ（辺）で結ばれたデータ構造
- 直線状の構造や格子状の構造に比べて構造が自由
- 様々な応用できる

例）「人間関係」「文中の単語の共起関係」「分子構造」「交通状況」など

Spatial GCNの概要

クラスターに分割する方法は様々ある。今回はあまり議論せず「凝集型」と呼ばれる方法を用いているらしい


局所性（「近くにあるノード」の決め方）

$$N_{\delta}(j) = \{i \in \Omega : W_{ij} > \delta\}$$

j の近くにあるノード（頂点）

それは i である（そして i はノードの集合 Ω に含まれている）

この i を決める基準は、「 W_{ij} が閾値である δ よりも大きいとき」というものである。
(ちなみに W_{ij} は i と j とを指定することで1つの値に決定する)




隣接関係（分割したクラスター内の要素同士の関係）

$$\mathcal{N}_k = \{\mathcal{N}_{k,i} ; i = 1 \dots d_{k-1}\}$$

第 k 層における、各クラスター内の要素同士の関係は

k と i とを指定することで知ることができる

i は分割したクラスターの第 i 番目ということ




引用の論文では

$$\begin{aligned} W_0 &= W \\ A_k(i, j) &= \sum_{s \in \Omega_k(i)} \sum_{t \in \Omega_k(j)} W_{k-1}(s, t), \quad (k \leq K) \\ W_k &= \text{rownormalize}(A_k), \quad (k \leq K) \\ \mathcal{N}_k &= \text{supp}(W_k), \quad (k \leq K) \end{aligned}$$

Spatial GCNの概要

Ω_k は、 Ω_{k-1} を d_k 個のクラスターに分割したものの



畳み込みの形式になっている！

プーリングの機能

活性化関数

第 k 層目の入力

第 k 層目のフィルターの数


第 k 層目の出力
= 第 $k+1$ 層目の入力

$$x_{k+1,j} = L_k h \left(\sum_{i=1}^{f_{k-1}} F_{k,i,j} x_{k,i} \right) \quad (j = 1 \dots f_k)$$

フィルター（隣接関係 \mathcal{N}_k のあるところだけ値を持つ「すかさか」の行列）

Spatial GCNの計算コスト

- 入力すべきパラメーターが多いほど計算コストは大きくなっていく傾向がある！
- そこでここではパラメーター数と計算コストを比例しているものとみなす



$$S_k \cdot |\Omega_k| \approx \alpha \cdot |\Omega_{k-1}|$$

$$x_{k+1,j} = L_k h \left(\sum_{i=1}^{f_{k-1}} F_{k,i,j} x_{k,i} \right) \quad (j = 1 \dots f_k)$$

$$O(S_k \cdot |\Omega_k| \cdot f_k \cdot f_{k-1}) = O(n)$$

隣接ノード数の平均 (\mathcal{N}_k から導く)

「 n のオーダー」
と読む
(n に比例する程
度の大きさという
意味)

Spectral GCN



この章の流れ

- 理解の前提となる事柄を解説する。

「グラフ」のフーリエ変換について議論
(少々長い！それでもざっくりとした説明。
「スペクトル解析」や「グラフ理論」につ
いて学習すると理解が深まる！)

- J.Brunaらが2014年に発表した
”Spectral Networks and Deep Locally Connected
Networks on Graphs“

の内容にも触れつつ

Ziwei Zhangらが2020年に発表した

“Deep Learning on Graphs: A Survey”


の内容をもとにSpectral GCNを紹介する。

様々な手法を比較したサーベイ論文
(これも無料で読める！)

- ざっくりと式の流れを追いかける。
- 計算コストについて簡単に考察する。


「グラフ」をフーリエ変換するには？

1次元の場合を思い出す…




(離散) フーリエ変換

$$F(t) = \sum_{x=0}^{N-1} f(x) \exp\left(-i \frac{2\pi t x}{N}\right)$$




注目部分を取り出す



逆 (離散) フーリエ変換


$$f(x) = \frac{1}{N} \sum_{t=0}^{N-1} F(t) \exp\left(i \frac{2\pi x t}{N}\right)$$



重み

- 1次元の場合の「重み」関数を、「グラフ」の場合に拡張するには？

「グラフ」をフーリエ変換するには？




$$f(t) = 100 \sin(2\pi \cdot 10t) \\ + 5 \sin(2\pi \cdot 42t) \\ + 20 \sin(2\pi \cdot 46t) \\ + 30 \sin(2\pi \cdot 48t)$$

(離散) フーリエ変換

$$F(t) = \sum_{x=0}^{N-1} f(x) \exp\left(-i \frac{2\pi t x}{N}\right)$$



$$e^{i\theta} = \cos \theta + i \sin \theta$$



$$\sin \theta = \frac{e^{i\theta} - e^{-i\theta}}{2i}$$

$$\frac{d^2}{dt^2} \sin \omega t = -\omega^2 \sin \omega t \\ \frac{d^2}{dt^2} e^{i\omega t} = -\omega^2 e^{i\omega t}$$

- 三角関数と指数関数は親戚
- もとの関数は「重み」関数の足し合わせでできている
- 「重み」関数の特徴 2階微分すると元にもどること

行列の固有値・固有ベクトル
の関係に似ている！

「グラフ」をフーリエ変換するには？

2階微分の性質とは？

$$\frac{d}{dx}f = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}$$

$$\frac{d^2}{dx^2}f = \lim_{\Delta x \rightarrow 0} \frac{\frac{f(x + \Delta x + \Delta x) - f(x + \Delta x)}{\Delta x} - \frac{f(x + \Delta x) - f(x)}{\Delta x}}{\Delta x}$$

$$= \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x + \Delta x) - f(x + \Delta x)}{(\Delta x)^2} - \frac{f(x + \Delta x) - f(x)}{(\Delta x)^2}$$

$$= \lim_{\Delta x \rightarrow 0} \frac{f(x + 2\Delta x) - 2f(x + \Delta x) + f(x)}{(\Delta x)^2}$$

$$\begin{aligned}\frac{d^2}{dt^2} \sin \omega t &= -\omega^2 \sin \omega t \\ \frac{d^2}{dt^2} e^{i\omega t} &= -\omega^2 e^{i\omega t}\end{aligned}$$

行列の固有値・固有ベクトルの関係に似ている！

$$= \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - 2f(x) + f(x - \Delta x)}{(\Delta x)^2}$$

と表現しても同様のこと


自分自身と

その両隣との差

- 2階微分の性質
- 「グラフ」における2階微分とは？ → 自分自身とその周辺との差！ → グラフラプラシアン
- グラフラプラシアンの固有ベクトルを「重み」関数にすればよい！

「グラフ」をフーリエ変換するには？

グラフラプラシアンはどんなものか



グラフラプラシアン

$$L = D - A$$

次数行列
「ノードから何本エッジが伸びているか」の情報

隣接行列
「どのノードにつながっているか」の情報

$$D = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 \\ 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 2 \end{pmatrix}$$

$$A = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 1 & 1 \\ 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{pmatrix}$$

$$L = \begin{pmatrix} 1 & -1 & 0 & 0 & 0 \\ -1 & 3 & -1 & -1 & 0 \\ 0 & -1 & 3 & -1 & -1 \\ 0 & 0 & -1 & 3 & -1 \\ 0 & 0 & -1 & -1 & 2 \end{pmatrix}$$

「グラフ」をフーリエ変換するには？

1次元の場合を思い出す…

$$\frac{d^2}{dt^2} \sin \omega t = -\omega^2 \sin \omega t$$
$$\frac{d^2}{dt^2} e^{i\omega t} = -\omega^2 e^{i\omega t}$$

行列の固有値・固有ベクトル
の関係に似ている！

$$F(t) = \sum_{x=0}^{N-1} f(x) \exp\left(-i \frac{2\pi t x}{N}\right)$$

$$u_1 * u_2 = \sum_n u_1(n) u_2(m, n)$$

$$\mathcal{F}(u_1 * u_2) = \mathcal{F}(u_1) \mathcal{F}(u_2)$$

$$u_1 * u_2 = \mathcal{F}^{-1}(\mathcal{F}(u_1) \mathcal{F}(u_2))$$

$$\mathbf{L} \vec{q} = \lambda \vec{q}$$
$$\mathbf{L} \mathbf{Q} = \mathbf{Q} \Lambda$$

$$\mathbf{Q} = \begin{pmatrix} \vec{q}_1 & \vec{q}_2 & \cdots \end{pmatrix}$$

$$\vec{F} = \mathcal{F}_G(\vec{f}) = \sum_n \vec{f} \cdot \vec{q}_n$$
$$\vec{F} = \mathcal{F}_G(\vec{f}) = \mathbf{Q}^\top \vec{f}$$
$$\vec{f} = \mathcal{F}_G^{-1}(\vec{F}) = \mathbf{Q} \vec{F}$$

$$\mathcal{F}_G(u_1 *_G u_2) = \mathcal{F}_G(u_1) \odot \mathcal{F}_G(u_2)$$



$$u_1 *_G u_2 = \mathcal{F}_G^{-1}(\mathcal{F}_G(u_1) \odot \mathcal{F}_G(u_2))$$

$$u_1 *_G u_2 = \mathbf{Q}((\mathbf{Q}^\top u_1) \odot (\mathbf{Q}^\top u_2))$$



Spectral GCNの概要

$$\mathbf{u}_1 *_G \mathbf{u}_2 = \mathbf{Q} \left(\left(\mathbf{Q}^T \mathbf{u}_1 \right) \odot \left(\mathbf{Q}^T \mathbf{u}_2 \right) \right)$$

$$\mathbf{u}' = \mathbf{Q} \Theta \mathbf{Q}^T \mathbf{u}$$



↓ 注目部分を取り出す

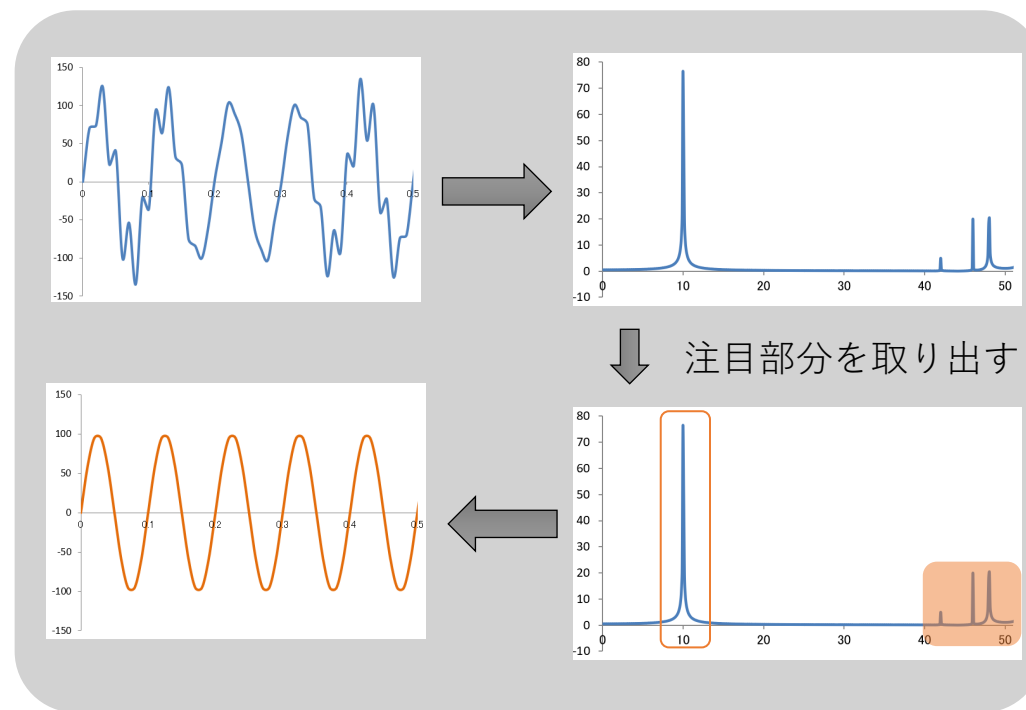


$$\mathbf{u}_j^{l+1} = \rho \left(\sum_{i=1}^{f_l} \mathbf{Q} \Theta_{i,j}^l \mathbf{Q}^T \mathbf{u}_i^l \right) \quad j = 1, \dots, f_{l+1}$$

活性化関数

Spectral GCNの計算コスト

$$\begin{aligned} L\vec{q} &= \lambda\vec{q} \\ LQ &= Q\Lambda \\ L &= Q\Lambda Q^T \end{aligned}$$



- 固有値分解をしなければならないので計算コストは高い
- 少なくとも $O(n^2)$ 場合によっては $O(n^3)$

全体の まとめ

- 畳み込み→フィルターをかけること
- これを「グラフ」に用いる→GCN
- Spatial GCN
「グラフ」を空間的に考えて畳み込む
- 計算コストは $O(n)$ ほど
- Spectral GCN
グラフをスペクトルに分解して畳み込む
- 計算コストは $O(n^2)$ 以上

